Прогноз спроса на домашние матчи «Авангарда»

DataMatch, технический трек

Команда «shertwg»: augustteske · sharbl4 (Антон) · ArinaPig (Арина) · Алиса

Задача и метрика

- Прогнозируем, сколько разовых билетов продастся на каждый из 17 оставшихся домашних матчей сезона 2025/26 в каждой из 8 ценовых зон: 136 прогнозов.
- Прогноз — итог за всё время продаж. Дата отсечки 15.12.2025: на 6 матчей продажи уже идут, на 11 ещё не открыты.
- Метрика — RMSE в билетах на зону. Ориентир — базовый прогноз: среднее по зоне за прошлые матчи.
- Ограничения: прогноз не меньше уже проданного и не больше свободных мест (места зоны минус абонементы).

17 × 8 = 136

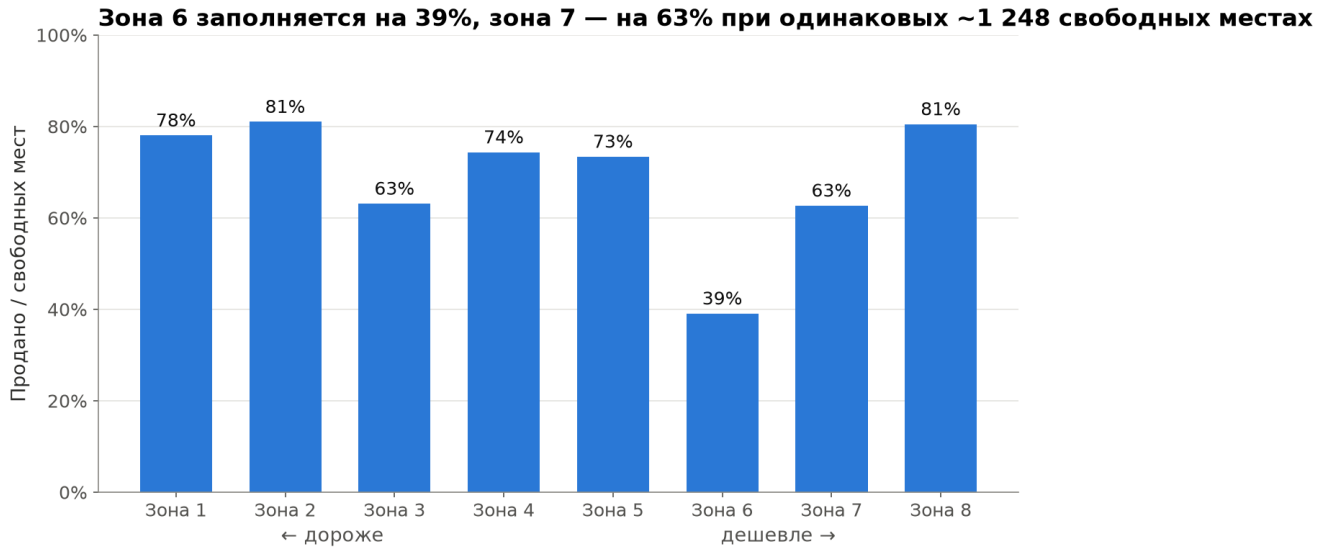
прогнозов: матч × зона

RMSE

метрика, билетов на зону

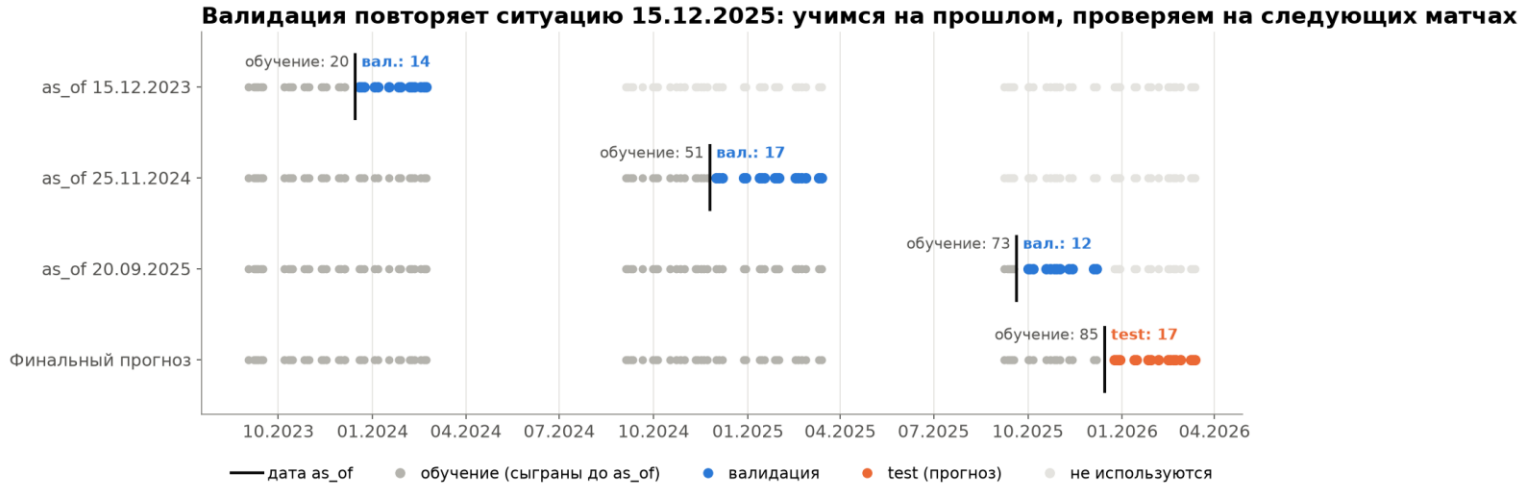
Данные и что мы в них увидели

- 102 домашних матча за 3 сезона: 85 сыгранных (02.09.2023–07.12.2025) для обучения и 17 для прогноза; 23 039 строк продаж по дням и зонам.
- Абонементы заметно сокращают свободные места: в зоне 1 из 1 141 места абонементами занято в среднем 545.
- Зоны заполняются очень по-разному: зоны 1, 2 и 8 — на 78–81%, а зона 6 — только на 39%, хотя свободных мест в ней столько же, сколько в зоне 7 (≈1 248), а та заполняется на 63%.
- Сезонность: в декабре прошлых сезонов в среднем 4 297 билетов за матч, в январе–феврале 4 889–4 936.



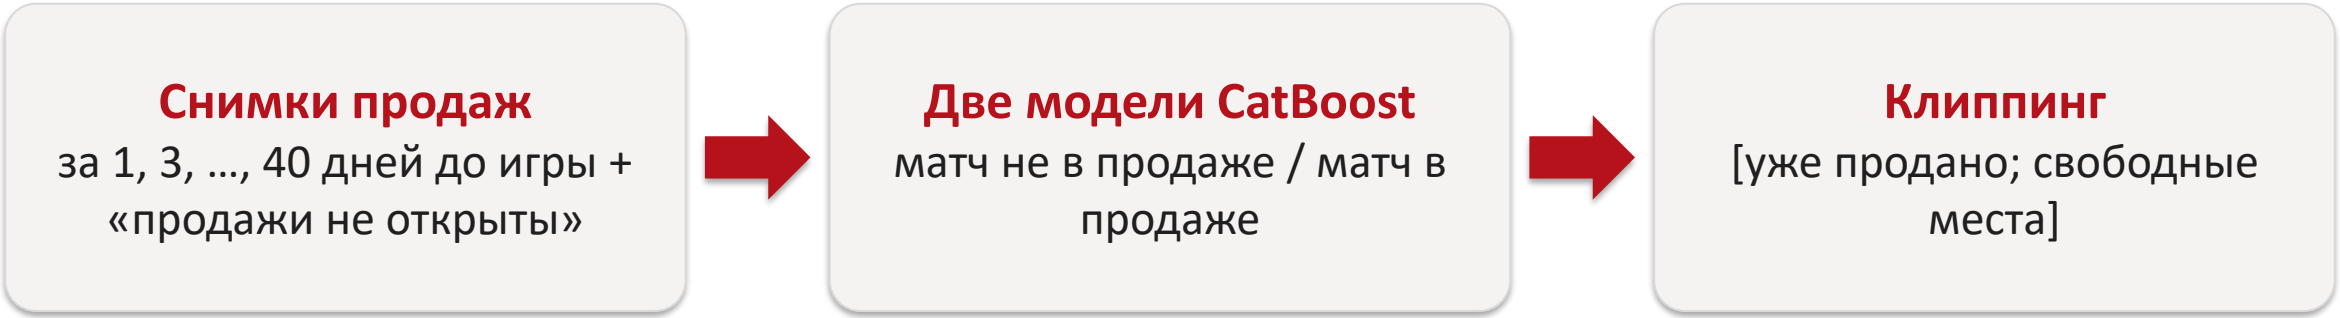
Проверка без утечек

- Валидация повторяет реальную ситуацию: выбираем дату «псевдо-сегодня» в прошлом, учимся только на сыгранных до неё матчах и прогнозируем следующие.
- 3 таких даты: 15.12.2023 (обучение на 20 матчах, проверка на 14), 25.11.2024 (51 → 17), 20.09.2025 (73 → 12). Всего 43 матча на проверке.
- Все признаки, включая продажи, результаты КХЛ и средние по соперникам, считаются только по данным до даты прогноза. Случайного перемешивания строк нет.
- Все модели сравниваются по одним правилам: тот же клиппинг (не меньше проданного, не больше свободных мест) и округление.



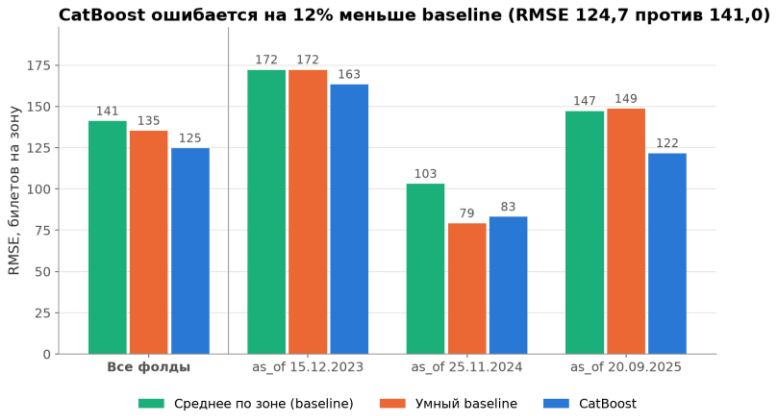
Подход: модель и признаки

- Два ориентира: baseline из задания (среднее по зоне за все прошлые матчи) и «умный baseline» — среднее по зоне за текущий сезон, не ниже уже проданного.
- Модель — CatBoost. Каждый сыгранный матч мы превращаем в несколько «снимков» продаж: за 1, 3, …, 40 дней до игры, плюс снимок «продажи ещё не открыты». Так модель учится и на матчах в продаже, и на ещё не открытых.
- Признаки: уровень зоны в сезоне и за последние 5 матчей; продажи на дату (продано, за 7 и 14 дней, темп относительно типичной кривой продаж); календарь (день недели, час, месяц); соперник (история продаж с ним в Омске, его сила в КХЛ); форма «Авангарда».
- Главный вклад дают продажи на дату: без них RMSE вырастает до 299,3. Вклад календаря и соперника в пределах погрешности валидации.



Результат: CatBoost точнее baseline на 12%

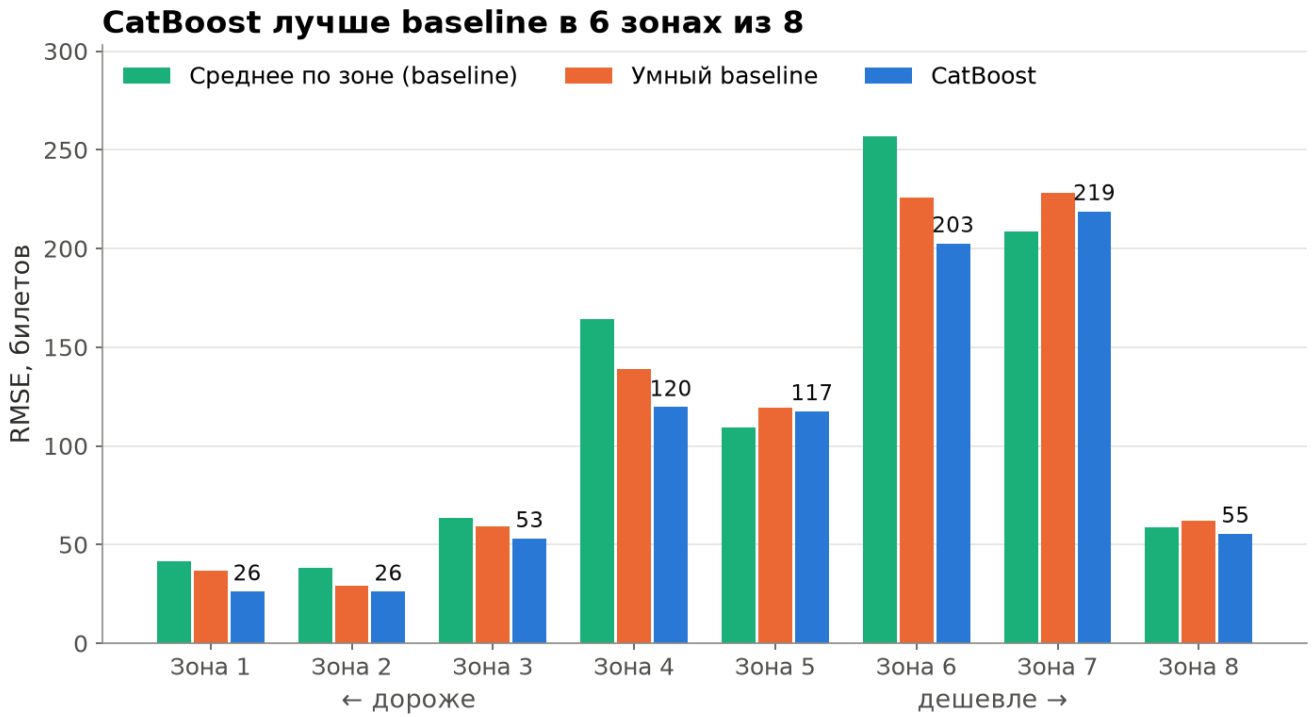
- RMSE на проверке: CatBoost 124,7, умный baseline 135,2, baseline из задания 141,0 (билетов на зону).
- По датам прогноза: 163,3 / 83,1 / 121,6 против baseline 172,2 / 103,0 / 147,2. CatBoost лучше baseline из задания на всех трёх датах; умный baseline обходит его только на дате 25.11.2024 (79,1 против 83,1).
- Против baseline из задания выигрыш надёжный: в среднем −16,4 билета на зону, 95% ДИ от −25,5 до −7,2; CatBoost лучше в 1 999 из 2 000 повторов бутстрэпа.
- Против умного baseline выигрыш есть, но на грани статистической значимости на 43 матчах: −10,5 билета, 95% ДИ от −20,4 до −0,1; CatBoost лучше в 1 953 из 2 000 повторов (≈98%).
- На матч целиком CatBoost на уровне простого среднего (RMSE 447,5 против 450,9 билета на матч); выигрыш — в распределении по зонам (WAPE по строкам 13,2% против 16,0%).



CatBoost минус…	Разница RMSE	95% ДИ	CatBoost лучше
baseline из задания	−16,4	−25,5 … −7,2	1 999 из 2 000
умный baseline	−10,5	−20,4 … −0,1	1 953 из 2 000

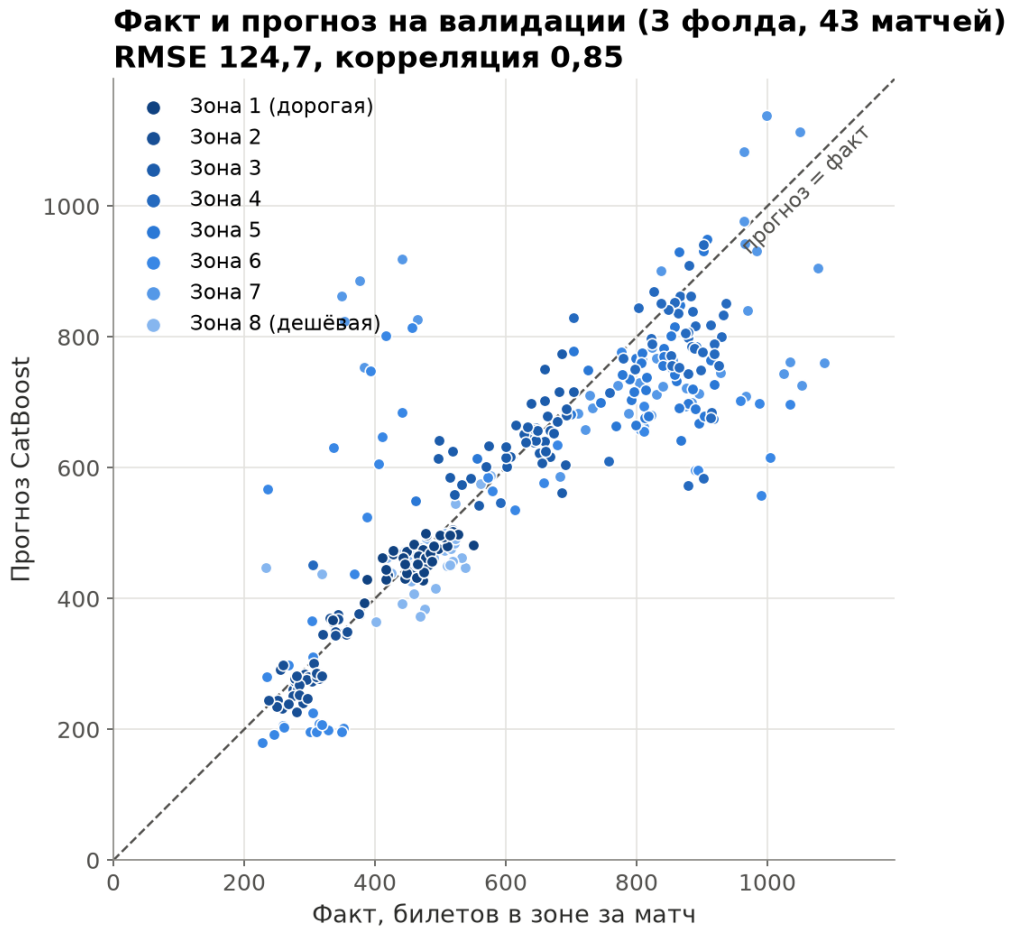
Точность по зонам

- CatBoost лучше baseline в 6 зонах из 8. Сильнее всего в зонах 4 (119,6 против 164,3) и 6 (202,6 против 257,0).
- В дорогих зонах 1–3 и в зоне 8 ошибка небольшая: 26–55 билетов.
- Хуже baseline в зонах 5 (117,5 против 109,4) и 7 (218,8 против 208,5).
- Почти вся ошибка сосредоточена в массовых зонах 6 и 7: RMSE 203 и 219.



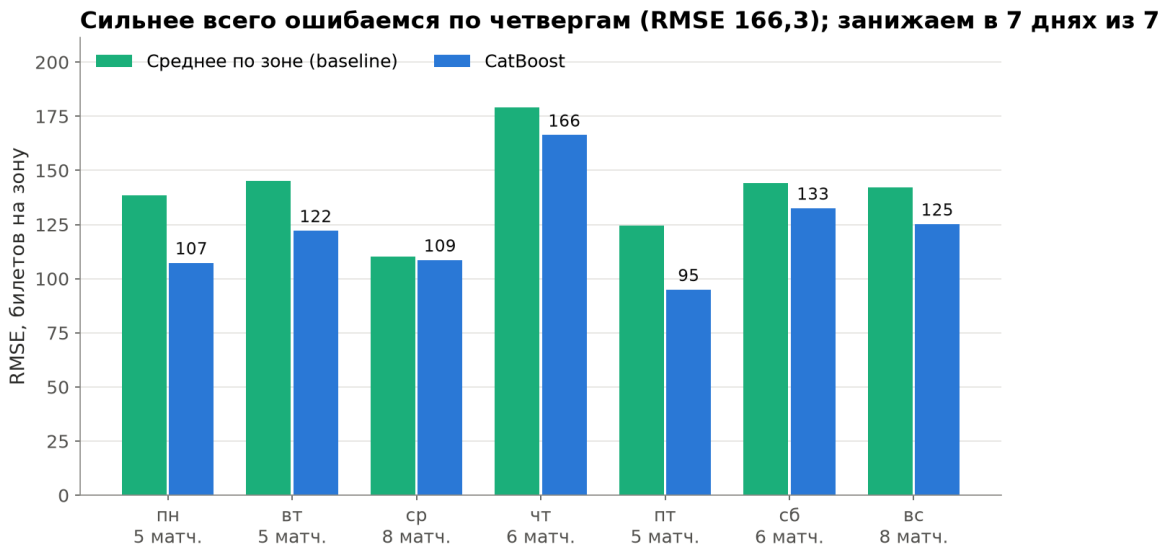
Разбор ошибок: зоны

- Самые крупные промахи — в зонах 6 и 7. Спрос между ними «переключается»: на одних матчах зона 6 продаёт около 1 000 билетов, а зона 7 около 350, на других наоборот (например, М029–М032).
- До открытия продаж такое переключение по нашим данным почти не предсказать. Когда продажи идут, модель видит его по уже проданному, поэтому на матчах в продаже ошибка 105,8, а на ещё не открытых 132,0.
- Модель в среднем немного занижает: на 27 билетов на зону. Сильнее всего в зонах 4 и 5 (−73 и −79).



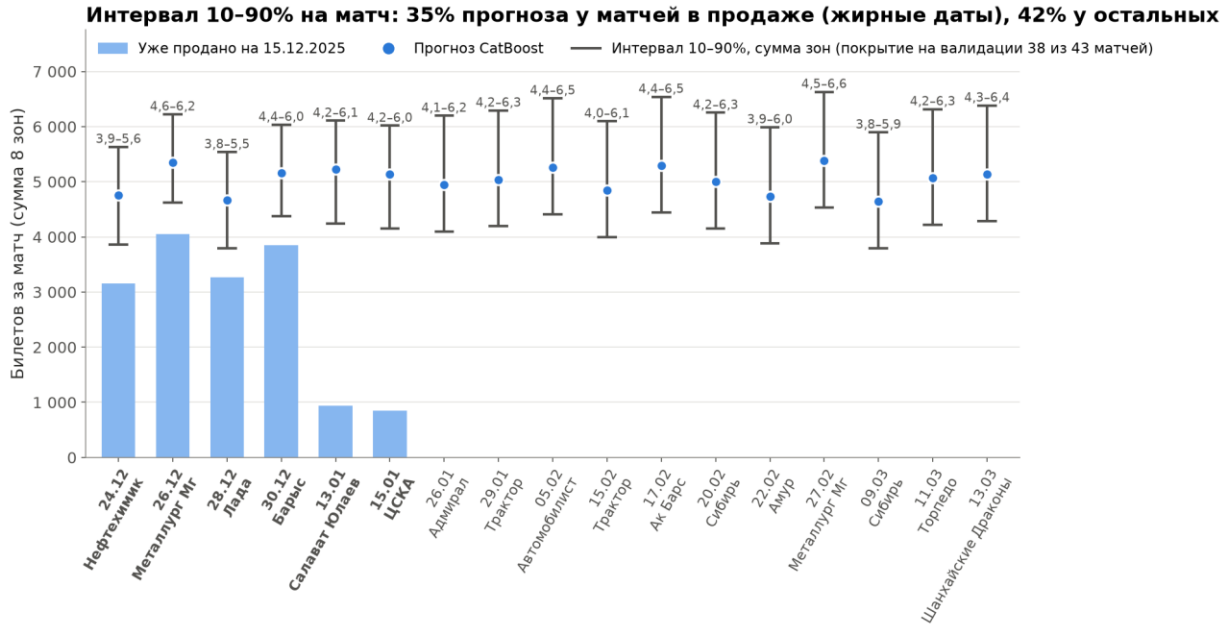
Разбор ошибок: дни недели и соперники

- По дням недели CatBoost лучше baseline каждый день. Сильнее всего ошибаемся по четвергам (RMSE 166), меньше всего по пятницам (95).
- Четверг выделяется не из-за дня недели. Ошибку дают 3 матча из 6 (M030, M034, M084), и 64% её приходится на зоны 6 и 7 — то самое переключение спроса со слайда 7.
- Модель занижает во все 7 дней недели: прогноз осторожный, а не перекошенный в какой-то день.
- По соперникам выводов не делаем: с каждым соперником на проверке было 1–5 матчей, у 13 соперников из 20 меньше трёх. Отдельные высокие ошибки (Сибирь 237, Спартак 195) — это 1–2 конкретных матча.



Прогноз на 17 матчей и новогодние матчи

- Прогноз на 17 матчей — 85 631 билет (5,0 тыс. за матч, +5% к сыгранной части сезона, 4 797); уже продано 16 106 на 6 матчей.
- Интервал на матч откалиброван на валидации (накрыл 38 из 43 матчей); по 17 матчам 71–105 тыс. билетов при прогнозе 85,6 тыс.
- Новогодние матчи 26–30.12 продаются раньше, но не больше: прошлые Новые годы закончили на 66–72% мест, модель ставит 73–77% — риск скорее в сторону переоценки.



Выводы и рекомендации клубу

Что сильнее всего определяет итог — темп уже начавшихся продаж. Без него ошибка растёт с 125 до 299. Рекомендация: пересчитывать прогноз каждую неделю по свежим продажам, особенно после открытия продаж на матч.

Новогодние матчи 26–30.12 — ранний спрос, а не аншлаг. Продажи идут в 1,6–2,1 раза быстрее обычного, но так было и в прошлые Новые годы, а закончили они на 66–72% мест. Ориентир — прошлые Новые годы, а не темп первых недель; стоит следить за остатком мест и обновлять прогноз по свежим продажам.

Признаки темпа продаж проверили: 3 варианта дают RMSE 122,6–124,6 против 124,7 у финальной модели, это в пределах шума (±3). Прогноз на новогодние матчи не меняется. Модель оставили без изменений.

Зона 6 — резерв выручки. Заполняемость 39% при таком же числе свободных мест, как в зоне 7 (63%), а спрос между зонами 6 и 7 переключается от матча к матчу. Стоит проверить цену и позиционирование зоны 6 (цен в наших данных нет, это гипотеза для клуба).

Все модели в среднем занижают, но знак смещения меняется от сезона к сезону (у CatBoost +76, −364 и −352 билета на матч по трём датам проверки), поэтому поправку не вводим.